

Uniwersytet Ekonomiczny w Katowicach



Zagadnienie predykcji decyzji kredytowej

Autor: Emilia Walczak

Data: 06.02. 2026 r.

1. Wstęp

Krótki opis analizowanej dziedziny

Analiza ryzyka kredytowego jest fundamentem funkcjonowania nowoczesnych instytucji finansowych. Proces ten polega na ocenie prawdopodobieństwa, z jakim potencjalny pożyczkobiorca wywiąże się ze swoich zobowiązań wobec banku. Tradycyjne metody oceny zdolności kredytowej coraz częściej są zastępowane zaawansowanymi systemami opartymi na sztucznej inteligencji i uczeniu maszynowym. Jak wskazują badania, wykorzystanie modeli takich jak Random Forest czy sieci neuronowe pozwala na znacznie bardziej precyzyjne przewidywanie statusu kredytu niż klasyczne metody statystyczne.

Kontekst badania

W obliczu dużej liczby wniosków kredytowych oraz konieczności minimalizacji ryzyka kredytowego, instytucje finansowe poszukują modeli, które potrafią wyłapać nieliniowe zależności między cechami demograficznymi, a sytuacją finansową klienta.

Literatura przedmiotu podkreśla, że kluczowym wyzwaniem w tej dziedzinie jest nie tylko dokładność predykcji, ale także interpretowalność wyników co jest szczególnie istotne w sektorze finansowym ze względów prawnych. Wiele artykułów badawczych wskazuje, że:

- Algorytmy uczenia maszynowego, takie jak Drzewa Decyzyjne, są cenione za przejrzystość reguł, co pozwala analitykom zrozumieć, dlaczego konkretny wniosek został odrzucony.
- Modele te muszą radzić sobie z problemem niezbalansowanych zbiorów danych oraz brakującymi informacjami, co jest powszechnym zjawiskiem w realnych bazach danych bankowych.

2. Cel i pytania badawcze

Cel badania

Głównym celem raportu jest opracowanie oraz porównanie efektywności wybranych modeli uczenia maszynowego (Drzewa Decyzyjne, Random Forest, Regresja Logistyczna, Sieci Neuronowe) w procesie klasyfikacji wniosków kredytowych. Badanie koncentruje się na identyfikacji kluczowych zmiennych finansowych i demograficznych, które determinują przyznanie pożyczki, oraz na ocenie, w jakim stopniu automatyzacja tego procesu może minimalizować ryzyko kredytowe instytucji przy zachowaniu wysokiej precyzji predykcyjnej.

Pytania badawcze

- 1. Która ze zmiennych wejściowych posiada największą moc predykcyjną w procesie decyzyjnym?**
- 2. Czy istnieje istotna statystycznie zależność między poziomem wykształcenia wnioskodawcy a statusem przyznania kredytu?.**
- 3. W jakim stopniu łączenie dochodów wnioskodawcy i współwnioskodawcy wpływa na celność modelu w porównaniu do analizy wyłącznie dochodu głównego?**
- 4. Który z testowanych algorytmów (Tree, Random Forest, SVM czy Neural Network) charakteryzuje się najwyższym wskaźnikiem AUC w warunkach występowania braków danych i wartości odstających?**

3. Opis danych:

Źródła danych

Zbiór danych pochodzi z witryny internetowej Kaggle: **Loan Prediction Problem Dataset**.

Charakterystyka zestawu danych

- Liczba wierszy (wniosków kredytowych): 614,**
- Liczba kolumn: 13 atrybutów,**

- **Zmienne kategoryczne:** Płeć, Stan cywilny, Liczba osób na utrzymaniu, Wykształcenie, Samozatrudnienie, Historia kredytowa oraz Typ obszaru.
- **Zmienne numeryczne:** Dochód wnioskodawcy, Dochód współwnioskodawcy, Kwota kredytu oraz Okres kredytowania.
- **Zmienna celu:** Loan_Status- przyjmująca wartości binarne: Y (przyznany) lub N (odrzucony).

Kroki przygotowania danych

Proces przygotowania danych został zrealizowany dwuetapowo:



1. **Audyt w Pythonie:** Za pomocą biblioteki Pandas zidentyfikowano braki danych oraz wartości odstające. Wykazano m.in. brakujące kwoty kredytu.

```
--- LICZBA BRAKÓW W KOLUMNACH ---
Gender                13
Married               3
Dependents            15
Self_Employed         32
CoapplicantIncome      2
LoanAmount            22
Loan_Amount_Term      14
Credit_History        50
```

```
--- PRZYKŁADOWE REKORDY Z BRAKAMI (NaN) ---
   Loan_ID  ApplicantIncome  LoanAmount
0  LP001002                5849         NaN
35 LP001106                2275         NaN
63 LP001213                4945         NaN
81 LP001266                2395         NaN
95 LP001326                6782         NaN
Granica górna: 10171.25
Liczba zidentyfikowanych outlierów: 50
   Loan_ID  ApplicantIncome
409 LP002317             81000
333 LP002101             63337
171 LP001585             51763
155 LP001536             39999
185 LP001640             39147
```

2. **Czyszczenie w Orange: Imputacja:** Wykorzystano widget Impute do uzupełnienia brakujących wartości (średnią dla zmiennych numerycznych i modą dla kategorycznych), co pozwoliło na uniknięcie odrzucenia niepełnych wniosków przez algorytmy.
 - **Selekcja cech:** Za pomocą widgetu Select Columns wykluczono identyfikatory (Loan_ID).
 - **Normalizacja:** Skalowanie w celu ujednolicenia zakresów dochodów i kwot kredytów.
 - **Korekta typów danych:** Zmienna Credit_History, która w pliku surowym była odczytywana jako liczba została ręcznie zmieniona na typ **Categorical**. Dzięki temu algorytmy

traktowały ją jako cechę jakościową, co jest zgodne z rzeczywistością biznesową.



Ocena jakości danych

Jakość danych oceniono jako dobrą, choć wymagającą uwagi w kilku obszarach:


- **Braki danych:** Występowały w kilku kluczowych kolumnach (np. LoanAmount, Credit_History), co wymagało wspomnianej imputacji.
- **Wartości odstające (Outliers):** Zidentyfikowano ekstremalnie wysokie dochody wnioskodawców (maks. 81 000), które mogą zniekształcać wyniki prostych modeli liniowych.
 - **Python:** Skrypt Python zidentyfikował 50 outlierów w dochodach (powyżej 10 171 USD). Analiza wizualna w Orange potwierdziła, że te ekstremalne wartości (max. 81 000 USD) nie zawsze przekładają się na wyższą kwotę pożyczki.
 - **Orange: Scatter Plot:** Outliery (wysokie dochody) są rozproszone, a decyzje odmowne (kolor N) zdarzają się nawet przy bardzo wysokich dochodach, jeśli historia kredytowa jest negatywna.

- **Niezbalansowanie klas:** Liczba przyznanych kredytów jest znacznie większa niż odrzuconych, co mogło skłaniać modele ku optymistycznym predykcjom i wymagało weryfikacji za pomocą metryki AUC.

Outlinery (wartości odstające)
zidentyfikowani przez skrypt Python

	Loan ID	Gender	Married	Dependents	Education	Self Employed	ApplicantIncome	CoupplicantIncome	LoanAmount	Loan Amount Term	Credit History	Property Area	Loan Status	Total Income
1	LP001020	Male	Yes	1.0	Graduate	No	12841	10968.0	349.0	360.0	1.0	Semiurban	N	23809
2	LP001100	Male	No	3.0	Graduate	No	12500	3000.0	320.0	360.0	1.0	Rural	N	15500
3	LP001186	Female	Yes	1.0	Graduate	Yes	11500	0.0	286.0	360.0	0.0	Urban	N	11500
4	LP001233	Male	Yes	1.0	Graduate	No	10750	0.0	312.0	360.0	1.0	Urban	Y	10750
5	LP001350	Male	Yes		Graduate	No	13650	0.0		360.0	1.0	Urban	Y	13650
6	LP001369	Male	Yes	2.0	Graduate	No	11417	1126.0	225.0	360.0	1.0	Urban	Y	12543
7	LP001401	Male	Yes	1.0	Graduate	No	14583	0.0	185.0	180.0	1.0	Rural	Y	14583
8	LP001422	Female	No	0.0	Graduate	No	10408	0.0	259.0	360.0	1.0	Urban	Y	10408
9	LP001448		Yes	3.0	Graduate	No	23803	0.0	370.0	360.0	1.0	Rural	Y	23803
10	LP001451	Male	Yes	1.0	Graduate	Yes	10513	3850.0	160.0	180.0	0.0	Urban	N	14363
11	LP001469	Male	No	0.0	Graduate	Yes	20166	0.0	650.0	480.0		Urban	Y	20166
12	LP001492	Male	No	0.0	Graduate	No	14999	0.0	242.0	360.0	0.0	Semiurban	N	14999
13	LP001508	Male	Yes	2.0	Graduate	No	11757	0.0	187.0	180.0	1.0	Urban	Y	11757
14	LP001516	Female	Yes	2.0	Graduate	No	14866	0.0	70.0	360.0	1.0	Urban	Y	14866
15	LP001536	Male	Yes	3.0	Graduate	No	39999	0.0	600.0	180.0	0.0	Semiurban	Y	39999
16	LP001585		Yes	3.0	Graduate	No	51763	0.0	700.0	300.0	1.0	Urban	Y	51763
17	LP001637	Male	Yes	1.0	Graduate	No	33846	0.0	260.0	360.0	1.0	Semiurban	N	33846
18	LP001640	Male	Yes	0.0	Graduate	Yes	39147	4750.0	120.0	360.0	1.0	Semiurban	Y	43897
19	LP001656	Male	No	0.0	Graduate	No	12000	0.0	164.0	360.0	1.0	Semiurban	N	12000
20	LP001673	Male	No	0.0	Graduate	Yes	11000	0.0	83.0	360.0	1.0	Urban	N	11000
21	LP001844	Male	No	0.0	Graduate	Yes	16250	0.0	192.0	360.0	0.0	Urban	N	16250
22	LP001859	Male	Yes	0.0	Graduate	No	14683	2100.0	304.0	360.0	1.0	Rural	N	16783
23	LP001891	Male	Yes	0.0	Graduate	No	11146	0.0	136.0	360.0	1.0	Urban	Y	11146
24	LP001907	Male	Yes	0.0	Graduate	No	14583	0.0	436.0	360.0	1.0	Semiurban	Y	14583
25	LP001922	Male	Yes	0.0	Graduate	No	20667	0.0		360.0	1.0	Rural	N	20667
26	LP001996	Male	No	0.0	Graduate	No	20233	0.0	480.0	360.0	1.0	Rural	N	20233
27	LP002065	Male	Yes	3.0	Graduate	No	15000	0.0	300.0	360.0	1.0	Rural	Y	15000
28	LP002101	Male	Yes	0.0	Graduate		63337	0.0	490.0	180.0	1.0	Urban	Y	63337
29	LP002191	Male	Yes	0.0	Graduate	No	19730	5266.0	570.0	360.0	1.0	Rural	N	24996
30	LP002194	Female	No	0.0	Graduate	Yes	15759	0.0	55.0	360.0	1.0	Semiurban	Y	15759
31	LP002317	Male	Yes	3.0	Graduate	No	81000	0.0	360.0	360.0	0.0	Rural	N	81000
32	LP002364	Male	Yes	0.0	Graduate	No	14880	0.0	96.0	360.0	1.0	Semiurban	Y	14880
33	LP002386	Male	No	0.0	Graduate		12876	0.0	405.0	360.0	1.0	Semiurban	Y	12876
34	LP002403	Male	No	0.0	Graduate	Yes	10416	0.0	187.0	360.0	0.0	Urban	N	10416
35	LP002422	Male	No	1.0	Graduate	No	37719	0.0	152.0	360.0	1.0	Semiurban	Y	37719
36	LP002501		Yes	0.0	Graduate	No	16652	0.0	110.0	360.0	1.0	Semiurban	Y	16652
37	LP002527	Male	Yes	2.0	Graduate	Yes	16535	1014.0	150.0	360.0	1.0	Rural	Y	17536
38	LP002531	Male	Yes	1.0	Graduate	Yes	16667	2250.0	86.0	360.0	1.0	Semiurban	Y	18917
39	LP002541	Male	Yes	0.0	Graduate	No	10833	0.0	234.0	360.0	1.0	Semiurban	Y	10833
40	LP002547	Male	Yes	1.0	Graduate	No	16333	0.0	500.0	360.0	1.0	Urban	N	16333
41	LP002582	Female	No	0.0	Not Graduate	Yes	17263	0.0	225.0	360.0	1.0	Semiurban	Y	17263
42	LP002624	Male	Yes	0.0	Graduate	No	20833	6667.0	480.0	360.0		Urban	Y	27500
43	LP002634	Female	No	1.0	Graduate	No	13262	0.0	40.0	360.0	1.0	Urban	Y	13262
44	LP002699	Male	Yes	2.0	Graduate	Yes	17500	0.0	400.0	360.0	1.0	Rural	Y	17500
45	LP002729	Male	No	1.0	Graduate	No	11250	0.0	196.0	360.0		Semiurban	N	11250
46	LP002731	Female	No	0.0	Not Graduate	Yes	18165	0.0	125.0	360.0	1.0	Urban	Y	18165
47	LP002813	Female	Yes	1.0	Graduate	Yes	19484	0.0	600.0	360.0	1.0	Semiurban	Y	19484
48	LP002855	Male	Yes	2.0	Graduate	No	16666	0.0	275.0	360.0	1.0	Urban	Y	16666
49	LP002938	Male	Yes	0.0	Graduate	Yes	16120	0.0	260.0	360.0	1.0	Urban	Y	16120
50	LP002959	Female	Yes	1.0	Graduate	No	12000	0.0	496.0	360.0	1.0	Semiurban	Y	12000

Outlinery charakteryzujący
się odmową ze strony banku
(kolor niebieski)



4. Przebieg badania

Metodologia badań

1. Charakterystyka zbioru danych i środowisko badawcze

Badanie przeprowadzono w oparciu o zbiór danych "Loan Prediction Problem", zawierający historyczne dane dotyczące wniosków kredytowych. Zbiór składa się ze zmiennych numerycznych oraz kategorycznych. Zmienną decyzyjną jest Loan_Status (Y/N).

W projekcie przyjęto podejście hybrydowe, wykorzystujące komplementarne zalety dwóch środowisk:

1. Python (Biblioteki Pandas, Matplotlib): Wykorzystany do wstępnej statystycznej oceny danych, generowania macierzy korelacji oraz zaawansowanej detekcji wartości odstających (outliers).

2. Orange Data Mining: Zastosowany do wizualnego modelowania procesów, budowy modeli predykcyjnych, wizualizacji drzew decyzyjnych oraz oceny skuteczności algorytmów.

2. Przetwarzanie wstępne danych:

Jakość danych wejściowych została zweryfikowana w wieloetapowym procesie czyszczenia i transformacji:

- **Obsługa braków danych:** Brakujące wartości w zmiennych kategorycznych uzupełniono modą (wartością najczęstszą).
- **Detekcja anomalii:** Zastosowano skrypt w języku Python wykorzystujący metodę rozstępu ćwiartkowego. Zidentyfikowano wartości odstające w zmiennych dochodowych.
- **Inżynieria cech:** W celu zwiększenia mocy predykcyjnej modeli utworzono nową zmienną syntetyczną Total_Income, stanowiącą sumę ApplicantIncome i CoapplicantIncome.

3. Selekcja cech i analiza istotności

Przed przystąpieniem do modelowania przeprowadzono analizę istotności atrybutów, aby uniknąć problemu współliniowości i szumu informacyjnego.

- **Macierz Korelacji (Heatmap):** Zbadano liniowe zależności między zmiennymi (współczynnik Pearsona).
- **Ranking atrybutów:** Wykorzystano metodę Information Gain oraz Gini Decrease, co pozwoliło na ustalenie hierarchii ważności cech, wskazując Credit_History jako wiodący predyktor.

4. Dobór i konfiguracja modeli

Do problemu klasyfikacji binarnej wybrano zestaw czterech zróżnicowanych algorytmów, reprezentujących różne podejścia matematyczne:

1. **Drzewo Decyzyjne:** Model bazowy, wybrany ze względu na wysoką interpretowalność.
2. **Las Losowy:** Model zespołowy, zastosowany w celu redukcji wariancji i zwiększenia odporności na wartości odstające.
3. **Regresja Logistyczna:** Model liniowy, służący jako punkt odniesienia do weryfikacji, czy problem decyzyjny ma naturę liniową.
4. **Sieć Neuronowa:** Model "czarnej skrzynki", zastosowany w celu sprawdzenia, czy głębokie uczenie pozwoli wykryć ukryte, nieliniowe wzorce niedostępne dla prostszych metod.

5. Ewaluacja

Weryfikację skuteczności modeli przeprowadzono przy użyciu metody walidacji krzyżowej (Cross-Validation) z podziałem na 10 podzbiorów ($k=10$). Pozwoliło to na uśrednienie wyników i uniknięcie błędu przeuczenia (overfitting).

Prezentacja wyników

1. Analiza Macierzy Korelacji (Python Heatmap)

Wygenerowana mapa ciepła dostarczyła kluczowych informacji o strukturze danych:

A. Weryfikacja zmiennej celu:


Analiza ostatniego wiersza macierzy pozwala jednoznacznie określić, które cechy mają bezpośrednie przełożenie liniowe na decyzję o przyznaniu kredytu:

1. **Dominacja Historii Kredytowej:** Zmienna Credit_History wykazuje najwyższy i jedyny istotny współczynnik korelacji z decyzją (0.56), co oznacza, że historia kredytowa jest najsilniejszym predykatorem w całym zbiorze danych.
2. **Brak liniowości dochodów względem decyzji:** Zaskakującym odkryciem jest niemal zerowa korelacja liniowa pomiędzy dochodem (ApplicantIncome: -0.00, Total_Income: -0.03) a statusem kredytu (Loan_Status_Num).
 - o **Wniosek:** Oznacza to, że sam wzrost dochodów nie zwiększa liniowo szansy na kredyt. Decyzja jest nieliniowa- można mieć wysoki dochód i otrzymać odmowę, co tłumaczy, dlaczego modele nieliniowe (Random Forest) osiągają lepsze wyniki niż prosta regresja.

B. Relacje wewnątrz cechowe:

Macierz ujawnia mechanizmy, jakimi banki prawdopodobnie wyliczają zdolność kredytową:

1. **Zależność: Dochód a Kwota Kredytu:** Istnieje wyraźna, dodatnia korelacja między dochodem a kwotą kredytu:
 - o ApplicantIncome vs LoanAmount: **0.57**
 - o Total_Income vs LoanAmount: **0.62**
 - o **Interpretacja:** Banki stosują sztywne algorytmy- im więcej zarabiasz, o tym więcej możesz wnioskować. Wyższy współczynnik dla Total_Income (0.62) dowodzi, że łączenie dochodów stworzyło lepszą zmienną objaśniającą dla wnioskowanej kwoty niż sam dochód wnioskodawcy.
2. **Niezależność zamożności od rzetelności:** Korelacja między dochodem (ApplicantIncome) a historią kredytową (Credit_History) wynosi **-0.01**.
 - o **Wniosek:** Cechy te są od siebie całkowicie niezależne. Wysokie zarobki nie implikują dobrej historii spłat, co jest kluczowym argumentem za traktowaniem Credit_History jako niezależnego "filtra bezpieczeństwa" w modelu.




2. Analiza czynników wpływu (Nomogram i Rank)

Zastosowanie **Nomogramu** pozwoliło na graficzne przedstawienie wag modelu regresji:

- **Absolutna dominacja Historii Kredytowej:** Na wykresie Nomogramu zmienna ta posiada jedną z najbardziej znaczących osi punktowych. Przeskok z wartości 0 na 1 generuje olbrzymi przyrost punktów w modelu. Oznacza to, że jest to czynnik krytyczny-wnioskodawca bez historii kredytowej startuje z ogromnym "debetem punktowym", którego niemal nie da się odrobić innymi czynnikami.
- **Rola dochodów:** Zmienne finansowe zajmują wysoką pozycję, ale ich wpływ jest rozłożony na długiej skali. Co istotne, Nomogram pokazuje, że wpływ dochodu nie jest prostym przełożeniem 1:1. Wysokie dochody dodają punkty, ale ich waga jednostkowa jest mniejsza niż posiadanie dobrej historii kredytowej.
- **Marginalne znaczenie cech demograficznych:** Zmienne takie jak Wykształcenie, Stan cywilny czy Samozatrudnienie posiadają bardzo krótkie osie na Nomogramie. Sugeruje to, że choć cechy te mogą przeważać szalę w sytuacjach granicznych, samodzielnie nie są w stanie zdecydować o przyznaniu kredytu.


- **Zgodność z widgetem Rank:** Wynik ten jest w pełni spójny z widgetem Rank, gdzie Credit_History uzyskało najwyższy współczynnik Information Gain.



3. Hierarchia decyzyjna:

Drzewo decyzyjne potwierdza logikę nomogramu w sposób binarny:

- **Korzeń (Root Node):** Credit_History jest pierwszym punktem podziału.
- Ścieżka dla braku historii (0) prowadzi niemal w 100% do odrzucenia wniosku (liść czerwony), co koresponduje z niską punktacją na nomogramie.



4. Analiza wielowymiarowa: Relacja Dochód-Kwota a status decyzji (Scatter Plot):

A. Stratyfikacja ze względu na wykształcenie (Kształty): Wykres pokazuje klarowną separację klientów.

Dominacja Absolwentów (Koła): W górnej i prawej części wykresu znajdują się tylko osoby z wykształceniem wyższym. To sugeruje, że osoby bez dyplomu (krzyżyki) praktycznie nie istnieją w grupie zamożnych klientów starających się o duże kwoty.


Szklany sufit "Not Graduate": Punkty w formie krzyżyków znajdują się głównie w lewym dolnym rogu (niskie dochody, małe kwoty). To sugeruje, że brak wykształcenia jest mocno powiązany z gorszą sytuacją finansową.

B. Anomalie i paradoksy:

Przypadek "Bogatego Odrzuconego": Na brzegu prawej osi (dochód około 81,000) można zauważyć niebieski punkt (N). Mimo wyjątkowo wysokiego dochodu, wniosek został odrzucony. Jest to wizualny dowód potwierdzający wcześniejsze tezy o kluczowym znaczeniu Historii Kredytowej – sam dochód nie zapewnia sukcesu.


Korelacja Liniowa: Widać wyraźny wzrost- gdy dochód (ApplicantIncome) rośnie, rośnie również wnioskowana kwota (LoanAmount). Punkty układają się w "stożek" rozszerzający się na prawo, co potwierdza wysoką korelację Pearsona ($r=0.57$) wykrytą wcześniej w analizie.

Wnioski: Wykres Scatter Plot pokazuje, że wykształcenie pełni rolę wskaźnika (zmienną pośrednią) dla statusu majątkowego.




5. Analiza Rozkładów i Anomalii:

- **Box Plot:** Wykresy potwierdzają obecność outlierów wykrytych w Pythonie. Co istotne, ekstremalne wartości występują w obu klasach decyzyjnych (Y/N), co dowodzi, że **sam wysoki dochód nie jest wystarczający do uzyskania kredytu**.



- **Charakterystyka populacji:** Rozkład kwoty kredytu jest prawostronnie skośny. Większość wniosków dotyczy kwot 100-150 tys., co stanowi strefę największej stabilności modelu. W obszarach skrajnych (bardzo niskie lub bardzo wysokie kwoty) precyzja modelu spada.



6. Ewaluacja Modeli- Zestawienie skuteczności algorytmów:

Model	AUC	CA	Precision	Wnioski
Random Forest	0.756	0.806	0.829	Najlepszy model. Skutecznie obsługuje nieliniowość i outliery.
Logistic Regression	0.754	0.804	0.822	Wysoki wynik dzięki silnej liniowej korelacji dochodu z kwotą kredytu.
Neural Network	0.739	0.791	0.791	Wynik dobry, ale model wymagał silniejszej normalizacji danych.
Tree	0.671	0.708	0.711	Najslabszy wynik.

Wnioski wynikające z analizy

1. Hierarchiczność kryteriów decyzyjnych (Rola "bezpiecznika")

Badanie wykazało, że zmienne wejściowe nie są traktowane przez algorytmy równoważnie. Zmienna Credit_History jest nadrzędna.

- Analiza drzewa decyzyjnego oraz nomogramu dowodzi, że negatywna historia kredytowa skutkuje niemal natychmiastowym odrzuceniem, niezależnie od wysokości dochodów czy wykształcenia wnioskodawcy.
- Dopiero po spełnieniu tego warunku koniecznego, modele analizują parametry finansowe.

2. Złożona relacja dochodowa

Zidentyfikowano istotną różnicę między ustalaniem kwoty kredytu a samą decyzją o jego przyznaniu:

- **Kwota kredytu:** Wykazuje silną korelację liniową z dochodem wnioskodawcy, co potwierdza, że banki stosują sztywne algorytmy wyliczania zdolności.
- **Decyzja:** Nie jest liniowa. Wykresy rozrzutu ujawniły, że w grupie osób o bardzo wysokich dochodach nadal występują liczne odmowy. Oznacza to, że wysoki status majątkowy jest warunkiem sprzyjającym, ale niewystarczającym.

3. Skuteczność inżynierii cech

Eksperyment potwierdził, że zsumowanie dochodów wnioskodawcy i współwnioskodawcy znacząco poprawia jakość modelowania. Zmienna Total_Income lepiej koreluje z kwotą kredytu niż dochód indywidualny, co pozwala modelom precyzyjniej oceniać zdolność kredytową gospodarstw domowych

4. Przewaga modeli zespołowych nad pojedynczymi

Mimo zidentyfikowania w analizie wstępnej licznych wartości odstających oraz braków danych, model **Random Forest** osiągnął najwyższą stabilność.

Odpowiedzi na pytania badawcze

1. Która ze zmiennych wejściowych posiada największą moc predykcyjną w procesie decyzyjnym?

Odpowiedź:

Bezdyskusyjnie najsilniejszą zmienną predykcyjną jest **Historia Kredytowa**.

Uzasadnienie:

- Macierz Korelacji wykazała najwyższy współczynnik korelacji Pearsona ze zmienną celu, podczas gdy inne zmienne oscylowały w granicach błędu statystycznego.
- Wizualizacja Nomogramu w programie Orange potwierdziła, że przeskok z braku historii (0) na historię pozytywną (1) generuje największy przyrost punktów w modelu.

2. Czy istnieje istotna statystycznie zależność między poziomem wykształcenia wnioskodawcy a statusem przyznania kredytu?

Odpowiedź:

Zależność istnieje, jednak ma ona charakter **pośredni i strukturalny**, a nie liniowy.

Uzasadnienie:

- Analiza wielowymiarowa (Scatter Plot) ujawniła, że wykształcenie (Graduate) jest silnie skorelowane z wyższymi dochodami i wnioskowaniem o wyższe kwoty kredytu.
- Osoby bez wyższego wykształcenia (Not Graduate) koncentrują się w strefach niższych dochodów, gdzie zagęszczenie decyzji odmownych jest statystycznie wyższe.

3. W jakim stopniu łączenie dochodów wnioskodawcy i współwnioskodawcy wpływa na celność modelu w porównaniu do analizy wyłącznie dochodu głównego?

Odpowiedź:

Zastosowanie inżynierii cech i wprowadzenie zmiennej zagregowanej **Total_Income** znacząco poprawiło odwzorowanie zdolności kredytowej.

Uzasadnienie:

- Macierz korelacji wykazała, że Total_Income silniej koreluje z wnioskowaną kwotą kredytu niż sam dochód wnioskodawcy
- Dla algorytmów uczenia maszynowego suma dochodów eliminuje szum informacyjny w przypadkach, gdy główny wnioskodawca nie posiada dochodu, ale jest zabezpieczony finansowo przez zamożnego współwnioskodawcę.

4. Który z testowanych algorytmów charakteryzuje się najwyższym wskaźnikiem AUC w warunkach występowania braków danych i wartości odstających?

Odpowiedź:

Najwyższą skuteczność i stabilność wykazał algorytm **Random Forest (Las Losowy)**, osiągając wskaźnik AUC na poziomie.

Uzasadnienie:

- W przeciwieństwie do pojedynczego Drzewa Decyzyjnego oraz Regresji Logistycznej, Las Losowy skutecznie poradził sobie z wartościami odstającymi w dochodach, wykrytymi na etapie analizy wykresów pudełkowych.

6. Podsumowanie

Najważniejsze obserwacje

Analiza danych przeprowadzona w Orange oraz Python doprowadziła do pewnych wniosków :

- **Dominacja Historii Kredytowej:** Niezależnie od przyjętej metody, zmienna Credit_History zawsze okazywała się najsilniejszym predykatorem.
- **Paradoks wysokich dochodów:** Scatter Plot ujawnił obecność licznych punktów odmownych w strefie wysokich zarobków. Obserwacja ta obala mit, że wysoki dochód automatycznie gwarantuje zdolność kredytową.

Kluczowe konkluzje

Na podstawie zgromadzonych obserwacji można wyciągnąć wnioski:

1. **Model dwuetapowej weryfikacji:** Proces decyzyjny banku nie jest liniową sumą punktów. Przypomina on strukturę hierarchiczną. Klient z negatywną historią jest odrzucany natychmiast, zanim algorytm w ogóle oceni jego dochody.
2. **Rekomendacja algorytmiczna:** Ze względu na występowanie nieliniowych zależności oraz wartości odstających, najlepszym modelem **Random Forest**. Wykazał on wyższą odporność na szum w danych niż klasyczne Drzewa Decyzyjne czy Regresja Logistyczna.
3. **Transparentność decyzji:** Choć Random Forest jest najskuteczniejszy, dla celów kontaktu z klientem (wyjaśnienie powodu odmowy) warto wspierać się **Nomogramem**. Pozwala on w prosty sposób wizualizować brakujące "punkty".

Syntetyczne ujęcie wyników

Badanie wykazało, że możliwe jest zbudowanie skutecznego systemu automatycznej oceny ryzyka kredytowego z precyzją sięgającą **81%**. Kluczem do sukcesu nie jest jednak sama wysokość zarobków wnioskodawcy, lecz ich stabilność potwierdzona historią spłat oraz wsparcie współwnioskodawcy.

7. Bibliografia

1. **Kang, Z. Z., et al. (2025).** *Loan Default Prediction Using Machine Learning Algorithms*. "Journal of Informatics and Web Engineering",
2. **Sarkar, et al. (2024).** *The Comprehensive Analysis of Bank Loan Approval Prediction Based on Machine Learning Models*. "SciTePress",
3. **MDPI (2025).** *A Secure Bank Loan Prediction System by Bridging Differential Privacy and Explainable Machine Learning*.

8. Załącznik: Wykorzystanie AI

Wykaz narzędzi AI użytych w projekcie

- **Generatywne modele językowe Gemini** oraz Chat GPT.
- **Algorytmy Uczenia Maszynowego:** W ramach środowiska **Orange Data Mining** oraz biblioteki **Scikit-learn (Python)** algorytmy predykcyjne:
 - Las Losowy,
 - Regresja Logistyczna,
 - Sieć Neuronowa,
 - Drzewo Decyzyjne.

Zakres wsparcia AI w przygotowaniu raportu

Wsparcie programistyczne:

- Optymalizacja skryptu w języku Python,
- Tłumaczenie wyników kodu na wnioski biznesowe.

Wsparcie analityczne i interpretacyjne:

- Pomoc w interpretacji złożonych wizualizacji, w tym **Nomogramu** oraz **Drzewa Decyzyjnego** (analiza ścieżek decyzyjnych).
- Sugerowanie metod wizualizacji wielowymiarowej (np. dobór parametrów dla widgetu Scatter Plot).

Ocena przydatności zastosowanych narzędzi AI

- Zastosowanie AI znacznie poprawiło finalny efekt raportu. Model językowy skutecznie wskazał, które zmienne mogą mieć kluczowe znaczenie, co pozwoliło na szybsze skonfigurowanie zmiennych np. widgetu Rank w Orange.
- Jednakże Generatywna AI wykazywała tendencję do "halucynowania" przy interpretacji specyficznych wykresów bez odpowiedniego kontekstu, co wymagało stałej analizy wygenerowanych treści.